


¿QUIEN SE VA Y PORQUE ? ANALISIS DE LA DESERCIÓN DE CLIENTES EN TELECOMUNICACIONES



Juan Sebastian Alvarez Ortegon, Maria Natalia Medina Rojas, Sol
Daniela Rodriguez Castellanos, Valery Mariana Sanchez Albarracin

¿CUÁL ES EL PROBLEMA?

CONTEXTO



La retención de clientes es uno de los principales retos de las empresas de telecomunicaciones, debido a la alta competencia y a la facilidad con la que los usuarios pueden cambiar de proveedor. Este abandono, conocido como churn, afecta directamente los ingresos de las empresas, por lo que es importante identificar a los clientes que tienen mayor probabilidad de abandonar el servicio.

El objetivo de este proyecto es analizar la relación entre las características de los clientes y su abandono, mediante limpieza, procesamiento y análisis exploratorio de datos en Python

Como Recorderis trabajamos con el Telco Customer Churn Dataset de Kaggle, la cual cuenta con 7,043 clientes y 21 variables, agrupadas en información demográfica (género, adulto mayor, pareja, dependientes), servicios contratados (tenure, telefonía, internet, seguridad, streaming, soporte) y facturación (contrato, método de pago, cargo mensual, cargo total, y la variable objetivo Churn).

customerID	gender	# SeniorCitiz...	Partner	Dependents	# tenure
7590-VHVEG	Female	0	Yes	No	1.0
5575-GNVDE	Male	0	No	No	34.0
3668-QPYBK	Male	0	No	No	2.0
7795-CFOCW	Male	0	No	No	45.0
9237-HQITU	Female	0	No	No	2.0
9305-CDSKC	Female	0	No	No	8.0
1452-KIOVK	Male	0	No	Yes	22.0
6713-OKOMC	Female	0	No	No	10.0
7892-POOKP	Female	0	Yes	No	
6388-TABGU	Male	0	No	Yes	62.0
9763-GRSKD	Male	0	Yes	Yes	13.0
7469-LKBCI	Male	0	No	No	16.0
8091-TTVAX	Male	0	Yes	No	
0280-XJGEX	Male	0	No	No	49.0
129-JLPIS	Male	0	No	No	

RECORDEMOS LA LIMPIEZA RAPIDAMENTE

CONTEXTO

1. Se normalizaron los nombres de columnas (minúsculas, sin espacios).

2. Se verificaron duplicados por customerID — no había ninguno.

3. Se limpiaron espacios sobrantes en las variables de texto.

4. TotalCharges se convirtió de texto a numérico con `pd.to_numeric`.

5. Los valores faltantes de tenure y MonthlyCharges se imputaron con la mediana,

6. Los pocos TotalCharges que seguían vacíos se calcularon como $\text{tenure} \times \text{MonthlyCharges}$.

7. En variables sin un valor confiable para imputar los faltantes se marcaron como "No registrado".

La limpieza de la base de datos permite organizar y corregir la información de los clientes para evitar errores en el análisis. Esto es importante porque los datos serán utilizados para identificar los factores relacionados con la deserción de clientes y construir modelos que permitan predecir quiénes podrían abandonar el servicio.


DE DONDE PARTIMOS

7,043 × 21
Clientes y variables
(Kaggle / IBM Telco
Churn)

8,250 → 0
Celdas vacías
corregidas en la
limpieza


26.5%
Tasa global de
abandono (Churn) en
la base

¿Qué relación existe entre el tipo de contrato, el servicio de internet, el método de pago y la antigüedad de los clientes con su abandono (churn)?




CHURN SEGÚN CONTRATO, INTERNET Y MÉTODO DE PAGO


ANÁLISIS EXPLORATORIO



El compromiso de largo plazo actúa como factor de retención: a mayor duración del contrato, menor el abandono.




La fibra óptica más que duplica el churn de DSL, posiblemente por precio, calidad o competencia.



Los pagos automáticos (transferencia o tarjeta) retienen mejor que los métodos manuales.

Tasa de churn por antigüedad (meses)



Perfil: cliente que se va vs. que permanece

Métrica	Se va	Permanece
Antigüedad promedio	17.8 meses	37.3 meses
Cargo mensual promedio	\$74.0 USD	\$62.5 USD
Cargo total acumulado	\$1,531.8	\$2,552.2

El cliente que abandona es, en promedio, más nuevo y paga una tarifa mensual más alta — su cargo total acumulado es menor solo por su corta permanencia.

Los primeros 12 meses son el periodo crítico de retención.

PERFIL DEL CLIENTE QUE ABANDONA

ANÁLISIS EXPLORATORIO

Métrica	Cliente que se va	Cliente que permanece	Lectura
Antigüedad promedio	17.8 meses	37.3 meses	Se va antes
Cargo mensual promedio	\$74.0 USD	\$62.5 USD	Paga 18% más
Cargo total acumulado	\$1,531.8 USD	\$2,552.2 USD	Menor por su corta permanencia

En conjunto: el cliente que abandona es relativamente nuevo y paga una tarifa mensual más alta.

Variables categóricas

H0: la variable es independiente del churn · H1: existe asociación

Variable	Chi²	p-valor	Conclusión
Tipo de contrato	1,184.60	< 0.001	Se rechaza H0
Servicio de internet	601.27	< 0.001	Se rechaza H0
Método de pago	648.14	< 0.001	Se rechaza H0

Las tres variables muestran asociación estadísticamente significativa con el churn (p < 0.05): se rechaza la hipótesis de independencia en todos los casos.

17.8 vs 37.3 meses

antigüedad promedio: clientes que se van vs. permanecen

VARIABLES NUMÉRICAS

Mann-Whitney U

Shapiro-Wilk descartó normalidad en tenure, monthlycharges y totalcharges (p < 0.05 en las tres). Por eso, en vez de un t-test clásico, se usó una prueba no paramétrica para comparar estas variables entre clientes que abandonan y que permanecen.

Esto permitió pasar de solo observar diferencias en los gráficos a comprobar, con evidencia estadística, que esas diferencias no se deben al azar.

MAYOR RIESGO DE ABANDONO

Contrato mes a mes

42.7% de churn

Internet de fibra óptica

41.5% de churn

Pago con cheque electrónico

45.3% de churn

Antigüedad de 0-12 meses

46.1% de churn

MAYOR RETENCIÓN

Contratos de 1 y 2 años

11.3% y 2.8% de churn

Mayor antigüedad (61-72 meses)

5.5% de churn

Métodos de pago automáticos

15-17% de churn

Estos hallazgos se confirman más adelante en la interpretación de los modelos predictivos.

¿QUÉ QUISIMOS PREDECIR Y CON QUÉ MODELOS?

EL PROBLEMA

Clasificación binaria

¿El cliente se va o se queda?

Churn = Yes → 1

Churn = No → 0

PREPARACIÓN

- 80% entrenamiento / 20% prueba (estratificado)
- 34 variables tras One-Hot Encoding

INTERPRETABILIDAD

Regresión logística

Modelo base para clasificación binaria. Sus coeficientes explican cuánto aumenta o disminuye la probabilidad de fuga según cada variable — justo lo que el negocio necesita para entender el por qué.


PODER PREDICTIVO

Random Forest

Combina muchos árboles de decisión. Captura relaciones no lineales e interacciones entre variables (contrato, internet, pago), y es más robusto frente a valores atípicos.

¿CUÁL MODELO FUNCIONÓ MEJOR?

Comparación de métricas (%)



LECTURA DE RESULTADOS

Random Forest obtuvo mejor accuracy, precision, recall y F1 que la regresión logística.

Pero la regresión logística obtuvo un ROC-AUC ligeramente superior (0.831 vs. 0.827): ningún modelo domina en absolutamente todo.

Random Forest detecta al 52.9% de los clientes que realmente abandonan (recall), frente a 50.5% de la regresión logística — la métrica más relevante para retención.

MATRIZ DE CONFUSIÓN

MODELADO PREDICTIVO

Random Forest sobre el conjunto de prueba (1,409 clientes)

No se va

Se va

922

predijo que se queda y se quedó

113

predijo que se va y se quedó

176

predijo que se queda y se fue

198

predijo que se va y se fue


¿QUÉ NOS DICE?

El modelo acierta bien identificando a quienes se quedan (922 de 1,035), pero de los 374 clientes que sí abandonaron, solo detecta 198 (52.9% de recall).

Los 176 falsos negativos son clientes en riesgo real que el modelo no marca — el costo de negocio más relevante a reducir.

En una campaña de retención, priorizar recall (aunque cues algo de precisión) evita perder más clientes reales.

Random Forest — importancia de variables



REGRESIÓN LOGÍSTICA — DIRECCIÓN DEL EFECTO

REDUCE la fuga

- Contrato de 2 años
- Mayor antigüedad (tenure)
- Contrato de 1 año

AUMENTA la fuga

- Internet de fibra óptica
- Pago con cheque electrónico
- Facturación sin papel

CONCLUSIONES

Contrato

Es el factor más determinante del abandono.

Antigüedad

A mayor tenure, menor probabilidad de abandono.

Fibra + cheque electrónico

Se asocian a mayor riesgo de churn.

Modelos

Ambos alcanzan ~79% de accuracy y AUC $\approx$ 0.83;
Random Forest destaca en desempeño general.




RECOMENDACIONES

- 1** Priorizar retención en clientes mes a mes con 0–12 meses de antigüedad.
- 2** Investigar las causas del churn en fibra óptica: precio, soporte y competencia.
- 3** Incentivar la migración de cheque electrónico a pagos automáticos.
- 4** Promover la migración de contratos mensuales a 1 o 2 años.

Objetivo final: usar los hallazgos para enfocar acciones de retención donde el riesgo es mayor.

REFERENCIAS

1. Jethwaaatmik. (2025). Telco customer churn dataset [Conjunto de datos]. [Kaggle. hello@reallygreatsite.com](https://www.kaggle.com/hello@reallygreatsitecom/telco-customer-churn)
2. Technology Networks. (s.f.). Mann-Whitney U test: Assumptions and example. Technology Networks. <https://www.technologynetworks.com/informatics/articles/mann-whitney-u-test-assumptions-and-example-363425>
3. Víctor Quijano. (s.f.). ¿Qué es el índice de deserción de clientes y cómo evitarlo? <https://victorquijano.com/blog/que-es-el-indice-de-desercion-de-clientes-y-como-evitarlo/>
4. Pandas Development Team. Pandas Documentation. <https://pandas.pydata.org/docs/>
5. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. <https://scikit-learn.org/stable/>
6. Virtanen, P., et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261-272. <https://scipy.org/>
7. Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90-95. <https://matplotlib.org/>



GRACIAS!!

